Predicción de los precios de viviendas implementando técnicas de Machine Learning

Juan Diego Muñetón Herrera

I. Descripción del problema

I-A. Contexto y utilidad

La estimación del precio de una vivienda constituye un problema relevante dentro del análisis de datos y del aprendizaje automático, debido a que el valor de una propiedad depende de características físicas, constructivas, funcionales y de localización. La determinación de este valor puede ser de utilidad para propietarios, compradores, agentes inmobiliarios y entidades financieras, al proporcionar estimaciones que sirvan como apoyo para procesos de valoración y toma de decisiones.

En este trabajo se aborda el problema de predicción del precio de venta de viviendas utilizando el conjunto de datos *House Prices: Advanced Regression Techniques*, correspondiente a propiedades residenciales de Ames, Iowa. El conjunto fue desarrollado a partir del trabajo de De Cock [1] y contiene información sobre características como superficie construida, calidad general, número de habitaciones, garaje, sótano, año de construcción, características exteriores y condiciones de venta.

El objetivo consiste en construir modelos de aprendizaje automático capaces de aprender la relación existente entre las características observadas de una vivienda y su precio de venta, evaluando posteriormente diferentes familias de modelos bajo una metodología de validación reproducible.

I-B. Composición de la base de datos

El conjunto de datos proporcionado para el problema se divide en `train.csv` y `test.csv`. El archivo de entrenamiento contiene 1460 observaciones y 81 columnas, mientras que el archivo de prueba contiene 1459 observaciones y 80 columnas. La diferencia se debe principalmente a que `train.csv` contiene la variable objetivo `SalePrice`, mientras que `test.csv` no.

El conjunto de entrenamiento contiene un identificador (`Id`), 79 variables explicativas y la variable objetivo `SalePrice`. Las variables explicativas describen diferentes aspectos de las propiedades y pueden clasificarse semánticamente en variables cuantitativas, discretas, temporales, ordinales, nominales y binarias.

Entre las variables cuantitativas se encuentran `LotArea`, `GrLivArea`, `TotalBsmtSF`, `1stFlrSF`, `2ndFlrSF` y `GarageArea`, que representan principalmente superficies o magnitudes físicas. Entre las variables discretas se encuentran `BedroomAbvGr`, `FullBath`, `Fireplaces` y `GarageCars`. Las variables temporales incluyen `YearBuilt`, `YearRemodAdd`, `GarageYrBlt`, `MoSold` y `YrSold`. También se dispone de variables ordinales relacionadas con la calidad o condición de las viviendas, como `OverallQual`, `OverallCond`, `ExterQual`, `KitchenQual`, `GarageQual` y `PoolQC`. Estas variables poseen un orden natural entre sus categorías y, por lo tanto, no deben tratarse de la misma manera que las variables nominales. Por otra parte, variables como `MSZoning`, `Neighborhood`, `HouseStyle`, `Foundation`, `Heating`, `GarageType`, `SaleType` y `SaleCondition` representan categorías sin una relación ordinal inherente. `MSSubClass`, aunque está almacenada numéricamente, también se considera categórica debido a que sus valores representan códigos de tipos de vivienda.

El análisis inicial mostró que el conjunto presenta valores faltantes en diferentes proporciones. Las mayores cantidades se encuentran en `PoolQC`, `MiscFeature`, `Alley`, `Fence`, `MasVnrType` y `FireplaceQu`. Sin embargo, estos valores no se deben interpretar siempre como observaciones desconocidas. En varias variables, la codificación `NA` representa la ausencia de una característica, por ejemplo, ausencia de piscina, garaje, sótano, chimenea, cerca o acceso por callejón. Esta distinción es relevante para evitar que la imputación estadística elimine información semántica del conjunto de datos.

Por esta razón, el tratamiento de los datos faltantes se realizará de acuerdo con la naturaleza de cada variable. Las ausencias estructurales se representarán explícitamente mediante categorías de ausencia o mediante cero cuando este represente correctamente la inexistencia de la característica. Para valores numéricos que correspondan a información realmente desconocida se empleará imputación mediante la mediana, mientras que las variables categóricas podrán utilizar una categoría explícita o una imputación apropiada.

I-C. Paradigma y configuración del aprendizaje

El problema se formula como un problema de aprendizaje supervisado de regresión, debido a que para cada vivienda del conjunto de entrenamiento se dispone tanto de un conjunto de características de entrada X como del valor conocido de la variable objetivo `SalePrice`. El propósito del aprendizaje consiste en aproximar una función

$$f : X \longrightarrow \texttt{SalePrice}, \tag{1}$$

capaz de generalizar a viviendas no observadas durante el entrenamiento.

La configuración propuesta contempla la comparación de cinco familias de modelos: Linear Regression como modelo

paramétrico, K-Nearest Neighbors Regressor (KNN) como modelo no paramétrico, Random Forest Regressor como método basado en árboles, Multilayer Perceptron (MLP) como red neuronal y Support Vector Regression (SVR) como método basado en máquinas de soporte vectorial.

Antes del entrenamiento, las variables serán sometidas a un preprocesamiento diferenciado de acuerdo con su naturaleza. Las variables nominales serán transformadas, las variables ordinales conservarán su orden mediante codificación y las variables binarias serán representadas numéricamente. Las variables numéricas serán imputadas cuando sea necesario y, para los modelos sensibles a la escala, serán estandarizadas mediante

$$z = \frac{x - \mu}{\sigma}, \tag{2}$$

donde x es el valor original, μ es la media calculada en el conjunto de entrenamiento y σ es su desviación estándar.

El preprocesamiento se implementará mediante estructuras de *pipeline*, de manera que los parámetros de imputación, codificación y escalamiento se aprendan exclusivamente a partir de los datos utilizados para entrenar cada partición. Esta estrategia evita la introducción de información procedente de los datos de validación en el proceso de entrenamiento.

Debido a la asimetría de `SalePrice` y a la métrica empleada por la competencia, se utilizará como variable objetivo de aprendizaje su transformación logarítmica:

$$y' = \ln(1 + \texttt{SalePrice}). \tag{3}$$

De esta manera, los modelos aprenderán una función de la forma

$$f(X) \approx \ln(1 + \texttt{SalePrice}). \tag{4}$$

Las predicciones podrán transformarse nuevamente a la escala monetaria mediante

$$\widehat{\texttt{SalePrice}} = \exp(\hat{y}') - 1. \tag{5}$$

La métrica principal de evaluación será el error cuadrático medio de la raíz en escala logarítmica (*Root Mean Squared Error*, RMSE), definido como

$$\mathrm{RMSE}_{\log} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y'_i - \hat{y}'_i)^2}, \tag{6}$$

donde y'_i representa el logaritmo del precio real transformado y $\hat{y}'_i$ la predicción del modelo en esa escala. Esta métrica constituye el criterio principal para la comparación de los modelos, mientras que RMSE en escala monetaria, MAE y R^2 se utilizarán como métricas complementarias para proporcionar una evaluación más completa del comportamiento predictivo.

Para la evaluación, inicialmente se separará el conjunto de entrenamiento: el 80 % de las observaciones se destinará al conjunto de desarrollo y el 20 % restante constituirá el conjunto de prueba interno. Este último permanecerá aislado durante la selección de modelos e hiperparámetros. Dentro del conjunto de desarrollo se utilizará validación cruzada de cinco particiones (*5-fold cross-validation*), mediante la cual se estimará el desempeño medio y su variabilidad.

La selección de hiperparámetros se realizará exclusivamente utilizando el conjunto de desarrollo y la validación cruzada. Una vez seleccionado el modelo, este será evaluado sobre el conjunto de prueba interno, que no habrá participado en las decisiones de modelado. Además del promedio de las métricas obtenidas mediante validación cruzada, se analizará su dispersión y se podrán estimar intervalos de confianza para caracterizar la incertidumbre asociada al desempeño.

Finalmente, el archivo `test.csv` no será utilizado como conjunto de evaluación durante el desarrollo del proyecto, debido a que no contiene los valores reales de `SalePrice`. Este conjunto será reservado para generar las predicciones finales del modelo seleccionado.

II. Estado del arte

La predicción de precios de vivienda mediante aprendizaje automático constituye un problema de regresión con múltiples variables de naturaleza heterogénea. El conjunto de datos de Ames, Iowa, fue presentado por De Cock como una alternativa al conjunto Boston Housing para proyectos de regresión. El conjunto original contiene información de 2930 propiedades vendidas entre 2006 y 2010, con variables nominales, ordinales, discretas y continuas relacionadas con las características de las viviendas [1]. Esta diversidad convierte a Ames en un escenario apropiado para comparar modelos de diferente naturaleza y complejidad.

Adamskiy et al. [2] estudiaron el problema de predicción de precios utilizando específicamente el conjunto Ames dentro de un marco de aprendizaje en línea. Los autores consideraron tanto los precios originales como sus transformaciones logarítmicas y utilizaron pérdida cuadrática para evaluar las predicciones. Como modelos base emplearon regresiones lineales y Random Forest, observando que los modelos de Random Forest proporcionaban mejores resultados que las regresiones lineales, aunque requerían mayor cantidad de datos para su entrenamiento. Este trabajo resulta especialmente relevante para el presente proyecto porque demuestra el uso de una transformación logarítmica del precio en el mismo conjunto de datos y permite relacionar directamente dos de los modelos seleccionados: regresión lineal y Random Forest [2].

Zhang [3] realizó una comparación de diferentes algoritmos de aprendizaje automático utilizando los datos de la competencia *House Prices: Advanced Regression Techniques* de Kaggle. El estudio considera K-Nearest Neighbors (KNN), Ridge Regression, Random Forest y XGBoost, utilizando la regresión lineal múltiple como modelo de referencia. Los resultados reportan un mejor desempeño de XGBoost frente al modelo lineal y los otros métodos. Adicionalmente, el autor incorpora TreeSHAP para interpretar las predicciones del modelo. Esta investigación es pertinente para el presente trabajo porque incluye KNN, regresión lineal y Random Forest, permitiendo establecer antecedentes directos para tres de los modelos que serán evaluados [3].

Sharma, Harsora y Ogunleye [4] presentan una comparación cercana al planteamiento de este proyecto. Los autores formulan la predicción del precio de vivienda como un problema de regresión utilizando datos de Ames y comparan regresión lineal múltiple, Support Vector Regression (SVR), Random Forest, Multilayer Perceptron (MLP) y XGBoost. El

estudio emplea procedimientos de ajuste de hiperparámetros y compara los modelos mediante diferentes métricas de error y capacidad explicativa. XGBoost obtiene el mejor desempeño global entre los modelos analizados. La importancia de este trabajo radica en que varios de los modelos seleccionados para el desarrollo de este proyecto coinciden con su propuesta [4].

Finalmente, Andrade-Girón, Marin-Rodriguez y Zuñiga-Rojas [5] estudian el efecto de la selección de características sobre la predicción de precios inmobiliarios utilizando diferentes modelos de ensamble. Los autores comparan Bagging, Random Forest, Gradient Boosting, AdaBoost, Stacking, Voting y Extra Trees, y emplean técnicas de selección como Recursive Feature Elimination (RFE), Random Forest y Boruta. Sus resultados muestran que Stacking obtiene un desempeño elevado utilizando el conjunto completo de características y que Boruta permite reducir considerablemente el número de variables manteniendo un desempeño competitivo. Aunque este trabajo aborda la reducción del número de variables mediante selección de características, constituye un antecedente relevante para la segunda etapa del presente proyecto, en la cual se analizará el efecto de una estrategia diferente de reducción dimensional basada en la extracción de características mediante PCA y UMAP [5].

En conjunto, la literatura revisada muestra que no existe un único modelo para la predicción de precios en Ames. Los resultados dependen de los modelos seleccionados, la representación de los datos, el tratamiento de las variables, la selección de características, los hiperparámetros y el protocolo de evaluación. Mientras algunos estudios encuentran mejores resultados mediante Random Forest, otros reportan ventajas para XGBoost o modelos de ensamble. Por lo tanto, resulta metodológicamente más apropiado realizar una comparación controlada entre diferentes modelos de aprendizaje que asumir previamente cuál será el modelo óptimo.

A partir de estos antecedentes, el presente proyecto propone comparar cinco familias de modelos: regresión lineal como referencia paramétrica, K-Nearest Neighbors como método no paramétrico, Random Forest como modelo de ensamble basado en árboles, Multilayer Perceptron como red neuronal y Support Vector Regression como método basado en máquinas de soporte vectorial. Todos los modelos serán evaluados bajo un protocolo común de preprocesamiento, validación cruzada y ajuste de hiperparámetros, utilizando principalmente el RMSE en escala logarítmica como métrica de evaluación. Para el entrenamiento, el precio de venta será transformado mediante $y' = \ln(1 + \texttt{SalePrice})$, de manera consistente con la métrica utilizada en la competencia. Posteriormente, los dos modelos con mejor desempeño serán sometidos a los experimentos de reducción de dimensionalidad mediante PCA y UMAP, con el objetivo de determinar si una representación con menor número de dimensiones permite conservar o mejorar la capacidad de generalización.

REFERENCIAS

[1] D. De Cock, "Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project," *Journal of Statistics Education*, vol. 19, no. 3, 2011, doi: 10.1080/10691898.2011.11889627.

[2] D. Adamskiy, A. Bellotti, R. Dzhamtyrova, and Y. Kalnishkan, "Aggregating Algorithm for prediction of packs," *Machine Learning*, vol. 108, pp. 1231–1260, 2019, doi: 10.1007/s10994-018-5769-2.

[3] L. Zhang, "Housing Price Prediction Using Machine Learning Algorithm," *Journal of World Economy*, vol. 2, no. 3, 2023, doi: 10.56397/JWE.2023.09.03.

[4] H. Sharma, H. Harsora, and B. Ogunleye, "An Optimal House Price Prediction Algorithm: XGBoost," *Analytics*, vol. 3, no. 1, pp. 30–45, 2024, doi: 10.3390/analytics3010003.

[5] D. C. Andrade-Girón, W. J. Marin-Rodriguez, and M. G. Zuñiga-Rojas, "Intelligent Feature Selection Ensemble Model for Price Prediction in Real Estate Markets," *Informatics*, vol. 12, no. 2, Art. no. 52, 2025, doi: 10.3390/informatics12020052.